

IMD1151 - CIÊNCIA DE DADOS

2025.2

Projeto da 3a unidade

Definição

O objetivo deste projeto é aplicar os conceitos aprendidos em aula para realizar um processo de descrição baseado em aprendizado de máquina não-supervisionado (agrupamento) ou estatística a um problema de sua escolha. Os discentes podem utilizar técnicas de agrupamento para extrair informações relevantes ou realizar previsões fundamentadas nos dados, explorando a capacidade dos modelos para extrair relações.

A ideia é aprofundar a análise e não se restringir somente a estatísticas descritivas simples, de forma que seja possível obter conclusões (ou fortes indícios) de elementos não presentes nos dados a partir da análise.

Os grupos podem utilizar a mesma base de dados do projeto da segunda unidade (se for apropriada) e realizar um aprofundamento da análise, buscando os elementos destacados acima.

No desenvolvimento do projeto, os discentes devem:

1. Explorar e preparar os dados:
 - a. Investigar e tratar a estrutura, características e qualidade dos dados.
 - b. Realizar pré-processamento necessário, como normalização, codificação e divisão de dados.
2. Aplicar modelos de aprendizado de máquina ou extrair informações por meio de inferência estatística:
 - a. Escolher um modelo apropriado ao problema (ex.: clustering ou análise de correlação).
 - b. Interpretar os resultados obtidos, explicando como o modelo responde ao problema proposto.
3. Responder ao problema previamente definido:
 - a. Formular perguntas baseadas no contexto do problema.
 - b. Realizar inferências ou descrever padrões relevantes no conjunto de dados.
4. Extrair e comunicar insights valiosos:
 - a. Relacionar os resultados obtidos com o contexto do problema escolhido.
 - b. Discutir limitações do modelo e possíveis melhorias.
5. Documentar e apresentar resultados:
 - a. Produzir um relatório técnico detalhado.
 - b. Preparar uma apresentação oral clara e objetiva, destacando os principais achados e metodologias empregadas.

O trabalho será realizado em grupos de até cinco integrantes e terá como entregáveis um relatório técnico, o código-fonte desenvolvido e uma apresentação oral de 12 minutos. A seguir, será dada uma descrição detalhada do projeto.

Descrição do Projeto

1. Escolha do Problema e Base de Dados
 - a. Definição do problema:
Escolha um tema ou problema relevante e interessante.
 - b. Seleção de uma base de dados:
 - i. Escolha uma base adequada ao problema, garantindo sua relevância para análise. Bases públicas, como Kaggle, IBGE, ou dados coletados por vocês, são recomendadas.
2. Metodologia do Trabalho
 - a. Dividam as tarefas no grupo para otimizar o desenvolvimento.
 - b. Planejem a análise em etapas:
 - i. Preparação dos dados.
 - ii. Análise de dados.
 - iii. Interpretação e comunicação dos resultados.
 - c. Documentem decisões e desafios enfrentados durante o projeto.
3. Entrega do projeto
 - a. Relatório técnico: um documento bem estruturado, detalhado abaixo, deve ser escrito e entregue.
 - b. Apresentação oral: uma exposição clara e visualmente atrativa dos principais resultados e insights, em até 12 minutos, seguida de uma sessão de perguntas.
 - c. Código-fonte: código utilizado.

Estrutura do Relatório Técnico

O relatório pode seguir o formato abaixo:

1. Capa
 - a. Nome do projeto,
 - b. nomes dos integrantes do grupo,
 - c. data de entrega.
2. Resumo (Abstract)
 - a. Apresentação sucinta do objetivo do projeto, descrição da base de dados, principais métodos utilizados e os principais resultados.
3. Introdução
 - a. Contextualização do problema.
 - b. Justificativa da escolha do problema e base de dados.
 - c. Objetivos específicos do projeto.
4. Descrição da Base de Dados
 - a. Origem e características gerais (ex.: número de registros, número de variáveis, tipo de variáveis, etc.).
 - b. Qualidade dos dados (presença de dados ausentes, valores inconsistentes, etc.).

- c. Discussão sobre os atributos mais relevantes.
- 5. Metodologia
 - a. Etapas seguidas para realizar a análise.
 - b. Métodos de tratamento de dados ausentes, remoção de outliers, criação de variáveis derivadas, etc.
 - c. Modelos de análise de dados utilizados.
 - d. Estratégia de avaliação (ex.: métricas de desempenho).
 - e. Ferramentas e bibliotecas utilizadas (ex.: pandas, matplotlib, seaborn, Power BI, etc.).
- 6. Resultados
 - a. Análise dos resultados gerados pelos modelos.
 - b. Interpretação das inferências e/ou descrições realizadas.
- 7. Discussão
 - a. Relevância dos resultados em relação ao problema.
 - b. Limitações do modelo e propostas de melhoria.
- 8. Conclusão
 - a. Resumo das principais descobertas e reflexões sobre o impacto do trabalho.
 - b. Propostas de estudos futuros ou abordagens alternativas.
- 9. Referências
 - a. Citações das fontes de dados, bibliotecas, e outros materiais consultados.
- 10. Apêndices (opcional)
 - a. Códigos relevantes, gráficos extras, ou tabelas completas.

Essa é apenas uma sugestão de estrutura. Não é necessário seguir essa estrutura.

Requisitos para a Apresentação Oral

- Duração: até 12 minutos de apresentação, com mais 2 minutos para perguntas.
- Formato: apresentem com o apoio de slides, priorizando gráficos, tabelas e imagens.
- Clareza: destaquem os principais resultados obtidos e expliquem as metodologias utilizadas.
- Participação: nem todos os membros precisam falar na apresentação, mas deve ficar clara qual a contribuição de cada um no desenvolvimento.

Obs: caso alguém tenha algum tipo de necessidade específica relativa à apresentação para a turma, falar com o professor.

Datas e Prazos

Os projetos serão apresentados nos dias 15 e 17/12/2025 e os entregáveis (apresentação, relatório e código-fonte) devem ser submetidos até o fim do dia 17 por meio de formulário eletrônico.